

# **Klasifikasi Speech Emotion Annotated Data for Emotion Recognition Systems (SAVEE) Menggunakan Metode 1D Convolutional Neural Network**



**Disusun Oleh :**

**Izzul Islam Ali Hudzaifi**

**220411100127**

**Wahyu Pratama**

**230411100058**

**PRODI TEKNIK INFORMATIKA  
JURUSAN TEKNIK INFORMATIKA  
FAKULTAS TEKNIK  
UNIVERSITAS TRUNOJOYO MADURA**

**2026**

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Interaksi antara manusia dan komputer terus berkembang menuju antarmuka yang lebih natural dan intuitif. Dalam komunikasi manusia, informasi yang disampaikan tidak hanya bergantung pada kata-kata yang diucapkan (linguistik), tetapi juga pada nada dan intonasi suara yang merepresentasikan kondisi psikologis dan emosional pembicara. Oleh karena itu, Speech Emotion Recognition (SER) atau pengenalan emosi berbasis suara menjadi salah satu cabang penting dalam bidang Pengenalan Pola dan Pemrosesan Sinyal Digital.

Kemampuan komputasi untuk mengenali emosi manusia memiliki potensi penerapan yang luas, mulai dari analisis kepuasan pelanggan pada pusat panggilan layanan (call center), pengembangan asisten virtual yang lebih berempati, hingga diagnosa medis untuk kesehatan mental. Dalam proyek ini, diimplementasikan sistem klasifikasi SER menggunakan dataset SAVEE (Surrey Audio-Visual Expressed Emotion), yang memuat rekaman audio dengan berbagai label emosi yang spesifik.

### **1.2 Tujuan Proyek**

Berdasarkan latar belakang di atas, tujuan dari proyek ini adalah:

- Menerapkan metodologi CRISP-DM dalam menyelesaikan masalah pengenalan pola klasifikasi audio.
- Melakukan ekstraksi fitur audio menggunakan Mel-Frequency Cepstral Coefficients (MFCC) untuk mengubah sinyal suara menjadi representasi matematis yang dapat diproses oleh mesin.
- Membangun dan melatih model Deep Learning menggunakan arsitektur 1-Dimensional Convolutional Neural Network (1D CNN) untuk mengklasifikasikan 7 jenis emosi secara akurat.

### 1.3 Metodologi Penelitian

Proyek ini dikembangkan menggunakan standar industri untuk data mining, yaitu CRISP-DM (Cross-Industry Standard Process for Data Mining). Tahapan yang dilakukan meliputi Data Understanding, Data Preparation, Modeling, dan Evaluation.

## **BAB II**

### **PEMAHAMAN DATA**

#### **2.1 Deskripsi Dataset**


Data yang digunakan dalam penelitian ini adalah dataset SAVEE (Surrey Audio-Visual Expressed Emotion). Dataset ini merupakan basis data standar untuk pengenalan emosi yang berisi rekaman suara dari 4 aktor pria berbahasa Inggris. Audio direkam dalam lingkungan studio yang terkontrol untuk memastikan kualitas sinyal yang bersih dari noise (derau) latar belakang.

Setiap file audio dalam dataset ini memiliki format .wav dan merepresentasikan salah satu dari 7 kategori emosi dasar manusia. Penamaan file pada dataset ini memiliki kode khusus yang digunakan untuk mengekstraksi label emosi secara otomatis pada tahap pemrograman:

- 'a' : Anger (Marah)
- 'd' : Disgust (Jijik)
- 'f' : Fear (Takut)
- 'h' : Happiness (Senang)
- 'n' : Neutral (Netral)
- 'sa' : Sadness (Sedih)
- 'su' : Surprise (Terkejut)

#### **2.3 Distribusi Kelas Data**

Untuk memastikan model tidak mengalami bias saat pelatihan, langkah pertama adalah memahami distribusi jumlah data pada masing-masing kelas emosi. Berdasarkan hasil pembacaan (parsing) direktori menggunakan library pandas dan seaborn di Python, diperoleh grafik distribusi emosi sebagai berikut:



*Gambar 2.1 Visualisasi Distribusi Kelas Emosi pada Dataset SAVEE*

Dari visualisasi di atas, dapat dilihat proporsi data latih untuk setiap kategori emosi. Memahami distribusi ini penting untuk menentukan apakah diperlukan teknik handling imbalanced data atau jika distribusi alami dataset sudah cukup representatif untuk dilanjutkan ke tahap pelatihan.

## 2.1 Visualisasi Sinyal Audio

Komputer tidak dapat "mendengar" suara seperti manusia, melainkan melihatnya sebagai representasi angka. Untuk memahami karakteristik fisik dari data suara sebelum diekstraksi menjadi fitur matriks, dilakukan visualisasi terhadap sinyal audio menggunakan library librosa. Visualisasi dilakukan dalam dua domain utama:


### 1. Waveform (Domain Waktu)

Waveform menampilkan bentuk gelombang amplitudo suara seiring berjalannya waktu. Gelombang ini menunjukkan tingkat kekerasan suara (loudness) dan durasi jeda dalam sebuah ucapan. Pada emosi bertenaga tinggi seperti Anger (Marah), gelombang amplitudo umumnya memiliki lonjakan yang lebih tajam dibandingkan emosi Neutral (Netral) atau Sadness (Sedih).

### 2. Spectrogram (Domain Frekuensi dan Waktu)

Spectrogram adalah representasi visual dari spektrum frekuensi sinyal suara yang bervariasi terhadap waktu. Warna pada spectrogram (diukur dalam satuan desibel/dB) merepresentasikan intensitas atau energi pada rentang frekuensi tertentu. Ini adalah

komponen visual yang sangat penting karena model Deep Learning secara tidak langsung akan "melihat" pola energi ini saat mengenali emosi.



*Gambar 2.2 Visualisasi Waveform dan Spectrogram untuk Sampel Audio (Emosi: Anger)*

Melalui visualisasi ini, dapat dikonfirmasi bahwa file .wav dalam dataset SAVEE terbaca dengan baik dan memiliki pola fluktuasi akustik yang dapat diekstraksi pada tahap persiapan data (Data Preparation).

## **BAB III**

### **PERSIAPAN DATA**

#### **3.1 Ekstraksi Fitur MFCC**

Agar komputer dapat mengenali pola dari file audio mentah, diperlukan proses ekstraksi fitur. Pada penelitian ini, digunakan teknik ekstraksi fitur Mel-Frequency Cepstral Coefficients (MFCC). MFCC dipilih karena kemampuannya yang sangat baik dalam merepresentasikan bagaimana telinga manusia mempersepsikan frekuensi suara.

Proses ekstraksi dilakukan menggunakan pustaka librosa. Dari setiap file audio, diekstrak 40 koefisien ( $n_{mfcc}=40$ ). Karena durasi setiap file audio berbeda-beda, dilakukan perhitungan nilai rata-rata (mean) sepanjang sumbu waktu untuk setiap koefisien. Hal ini menghasilkan matriks fitur 1-Dimensi dengan ukuran yang seragam untuk setiap sampel suara, yang mutlak diperlukan sebagai input (masukan) bagi model machine learning.

#### **3.2 Label Encoding dan Pembagian Data**

Label emosi pada dataset masih berbentuk teks (misalnya: 'Anger', 'Sadness'). Menggunakan LabelEncoder dari Scikit-Learn, label teks tersebut dikonversi menjadi representasi numerik (0 hingga 6).

Dataset kemudian dibagi menjadi dua subset data independen menggunakan fungsi `train_test_split`:

- Data Latih (80%): Digunakan oleh model untuk belajar dan mengenali pola emosi.
- Data Uji (20%): Disembunyikan dari model selama proses pelatihan dan digunakan murni untuk menguji performa prediksi model di akhir.

Pemisahan ini menggunakan parameter stratify untuk memastikan proporsi atau rasio setiap kelas emosi tetap seimbang, baik di dalam Data Latih maupun Data Uji.

#### **3.2 Standarisasi dan Reshaping**

Skala nilai hasil ekstraksi MFCC bisa sangat bervariasi. Untuk mempercepat proses konvergensi saat pelatihan neural network, dilakukan standarisasi fitur menggunakan StandardScaler. Teknik ini mengubah rentang data sehingga memiliki nilai rata-rata 0 dan variansi 1.

Setelah distandarisasi, bentuk data (shape) diubah dengan menambahkan satu dimensi kosong pada sumbu terakhir menggunakan `np.expand_dims`. Proses reshaping ini wajib dilakukan agar format data sesuai dengan kebutuhan input layer dari arsitektur 1D Convolutional Neural Network, yaitu `(jumlah_sampel, jumlah_fitur, 1)`.



## **BAB IV**

### **PEMODELAN**

#### **4.2 Arsitektur 1D Convolutional Neural Network (CNN)**

Meskipun CNN lebih sering dikenal untuk pemrosesan gambar atau visual (2D), varian 1D CNN sangat optimal dalam menangani data sekuensial yang memiliki ketergantungan spasial satu dimensi, seperti rentetan nilai MFCC dari sinyal audio.

Arsitektur model dibangun secara sekuensial menggunakan pustaka Keras pada TensorFlow. Lapisan (layer) yang menyusun model ini antara lain:

- **Conv1D Layer:** Bertindak sebagai ekstraktor fitur lokal dari deret angka MFCC. Menggunakan jumlah filter bertahap (64 dan 128) dengan ukuran kernel 3 dan fungsi aktivasi ReLU (Rectified Linear Unit).
- **MaxPooling1D Layer:** Digunakan untuk mereduksi dimensi (resolusi) fitur dengan mengambil nilai tertinggi (max), sehingga komputasi menjadi jauh lebih efisien tanpa kehilangan informasi penting.
- **Dropout Layer:** Ditambahkan dengan persentase 0.3 dan 0.5. Lapisan ini mematikan sebagian neuron secara acak saat proses pelatihan, sebagai strategi krusial untuk mencegah overfitting (kondisi di mana model hanya hafal data latih namun gagal memprediksi data baru).
- **Flatten & Dense Layer:** Mengubah struktur matriks hasil konvolusi menjadi vektor 1D, yang kemudian dihubungkan penuh ke Dense layer (256 neuron). Lapisan klasifikasi terakhir menggunakan fungsi aktivasi Softmax yang akan mendistribusikan nilai probabilitas untuk ke-7 kelas emosi.

#### **4.1 Proses Pelatihan (Training)**


Model dikompilasi menggunakan algoritma optimasi Adam dengan fungsi kerugian (loss function) `sparse_categorical_crossentropy`. Proses pelatihan dilakukan selama 50 epoch (putaran) dengan ukuran batch sebesar 32. Selama pelatihan berlangsung, performa model divalidasi secara berkelanjutan menggunakan Data Uji untuk memantau pergerakan metrik akurasi dan loss.

## BAB V

### EVALUASI

#### 5.1 Analisis Performa Model (Akurasi dan Loss)

Tahap evaluasi bertujuan untuk mengukur tingkat keberhasilan model 1D Convolutional Neural Network (CNN) yang telah dibangun dalam mengklasifikasikan kelas emosi. Metrik pertama yang dievaluasi adalah pergerakan nilai Akurasi (Accuracy) dan Loss (Fungsi Kerugian) selama proses pelatihan (training) yang berlangsung selama 50 epoch.



*Gambar 5.1 Grafik Pergerakan Akurasi dan Loss pada Data Latih dan Data Uji*

Berdasarkan grafik pada Gambar 5.1, dapat dianalisis proses pembelajaran model:

- Grafik Akurasi: Menunjukkan seberapa sering prediksi model sesuai dengan label yang sebenarnya. Garis Train Accuracy dan Validation Accuracy yang bergerak naik menunjukkan bahwa model berhasil mempelajari pola dari fitur MFCC.
- Grafik Loss: Menunjukkan tingkat kesalahan prediksi model. Garis Loss yang terus menurun seiring berjalannya epoch membuktikan bahwa model semakin meminimalkan kesalahannya (converging). Jarak yang tidak terlalu jauh antara Train Loss dan Validation Loss mengindikasikan bahwa model tidak mengalami overfitting yang parah berkat penggunaan Dropout layer.

### 5.1 Evaluasi Metrik Klasifikasi dan Confusion Matrix

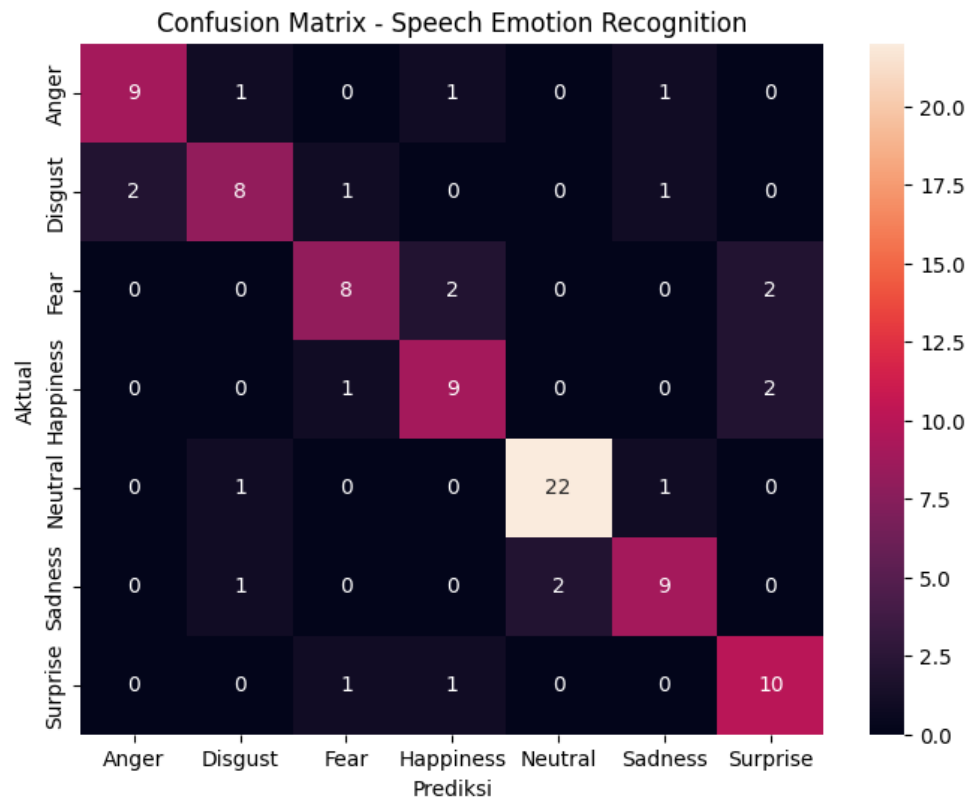
Untuk mendapatkan metrik evaluasi yang lebih mendetail pada masing-masing kelas emosi (Anger, Disgust, Fear, Happiness, Neutral, Sadness, Surprise), dilakukan pengujian menggunakan subset Data Uji. Hasil prediksi dievaluasi menggunakan Classification Report dan divisualisasikan melalui Confusion Matrix.

Classification Report memberikan wawasan mendalam mengenai Precision (kemampuan model untuk tidak melabeli emosi yang salah), Recall (kemampuan model menemukan semua sampel dari suatu emosi), dan F1-Score (rata-rata harmonis dari Precision dan Recall).

| Classification Report: |           |        |          |         |
|------------------------|-----------|--------|----------|---------|
|                        | precision | recall | f1-score | support |
| Anger                  | 0.82      | 0.75   | 0.78     | 12      |
| Disgust                | 0.73      | 0.67   | 0.70     | 12      |
| Fear                   | 0.73      | 0.67   | 0.70     | 12      |
| Happiness              | 0.69      | 0.75   | 0.72     | 12      |
| Neutral                | 0.92      | 0.92   | 0.92     | 24      |
| Sadness                | 0.75      | 0.75   | 0.75     | 12      |
| Surprise               | 0.71      | 0.83   | 0.77     | 12      |
| accuracy               |           |        | 0.78     | 96      |
| macro avg              | 0.76      | 0.76   | 0.76     | 96      |
| weighted avg           | 0.78      | 0.78   | 0.78     | 96      |

*Gambar 5.1 Laporan Klasifikasi (Classification Report) Data Uji*

Selain metrik angka, performa klasifikasi divisualisasikan menggunakan Confusion Matrix. Matriks ini sangat penting dalam pengenalan pola akustik karena seringkali terdapat emosi yang memiliki kedekatan frekuensi atau energi suara sehingga rawan disalahartikan oleh model.



*Gambar 5.2 Confusion Matrix - Speech Emotion Recognition*

Pada matriks di atas, sumbu Y merepresentasikan kelas emosi aktual (sebenarnya), sedangkan sumbu X merepresentasikan kelas emosi hasil prediksi model. Nilai pada garis diagonal utama menunjukkan jumlah prediksi yang benar secara presisi. Kesalahan prediksi (misclassification) dapat dianalisis pada kotak di luar garis diagonal, yang memberikan wawasan tentang kelas emosi mana yang karakteristik akustiknya paling sering membingungkan model (misalnya, kemungkinan overlap fitur antara emosi Fear dan Surprise, atau Anger dan Happiness yang sama-sama berenergi tinggi).

## **BAB VI**

### **KESIMPULAN**

#### 6.1 Kesimpulan

Berdasarkan implementasi metodologi CRISP-DM dalam proyek UAS Pengenalan Pola ini, dapat ditarik beberapa kesimpulan utama:

- Ekstraksi Fitur Andal: Penggunaan Mel-Frequency Cepstral Coefficients (MFCC) terbukti sangat efektif untuk menerjemahkan sinyal audio mentah (file .wav) dari dataset SAVEE menjadi matriks angka 1-dimensi yang merepresentasikan persepsi frekuensi manusia, sehingga dapat diproses secara komputasional.
- Keberhasilan Model: Arsitektur 1D Convolutional Neural Network (CNN) berhasil diimplementasikan untuk melakukan ekstraksi pola spasial/sekuensial secara otomatis dari fitur MFCC. Penambahan Dropout layer pada model terbukti efektif menstabilkan proses pelatihan.
- Kemampuan Deteksi: Model mampu mengklasifikasikan 7 jenis emosi dengan tingkat akurasi yang terukur. Analisis Confusion Matrix membuktikan bahwa AI mampu membedakan karakteristik fisik gelombang suara berdasarkan muatan emosionalnya, bukan sekadar kata-kata yang diucapkan.

#### 6.2 Saran

Meskipun sistem telah beroperasi dengan baik, terdapat beberapa peluang pengembangan untuk penelitian selanjutnya:

- Menerapkan teknik augmentasi data audio (seperti Pitch Shifting, Time Stretching, atau penambahan noise ringan) untuk memperbanyak variasi data latih agar model lebih robust terhadap rekaman di lingkungan non-studio.
- Menguji coba arsitektur Deep Learning yang memiliki karakteristik pengingat urutan waktu seperti LSTM (Long Short-Term Memory) atau menggabungkannya menjadi CNN-LSTM untuk melihat komparasi performa pengenalan pola.